

Семён Давшиц

Data Scientist / ML-инженер · стажировка

Москва · +7 977 284-01-54 · s.davshits@yandex.ru · t.me/SeMe4KO0 · github.com/SeMe4K-0

Студент 4 курса МГТУ им. Н. Э. Баумана, кафедра ИУ5. Модели на табличных данных и временных рядах, uplift-моделирование и статистика экспериментов; также computer vision и аудио. Довожу модели до сервиса с API и Docker.

ПРОЕКТЫ

X5 RetailHero - uplift-моделирование: кому рассылка меняет поведение

CatBoost · PostgreSQL · dbt

- T/S/X-learner на CatBoost по данным с честной рандомизацией; Qini, AUUC и uplift@k реализованы без готовых библиотек. Признаки из 45.8 млн строк чеков с корректностью на момент времени (PostgreSQL, dbt, 42 теста).
- Ранжирование по вероятности отклика хуже случайного: топ-10 % по отклику и по приросту пересекаются на **0.44 %** при случайном уровне 10 %. Uplift-модель даёт $\Delta \text{uplift@10 \%} = +9.53 \text{ п.п.}$ [+6.63; +12.54], бутстрап 2000 реплик.
- Эффект таргетинга по отклику статистически различим, но убыточен: 0.53 п.п. при точке окупаемости 4.67. Переход к таргетингу по приросту даёт **+612 тыс. ₽** на кампанию.
- План эксперимента зафиксирован до обучения моделей, аудитор утечек из будущего проверен мутационным тестом.

E-CUP 2026 (Ozon) - прогноз GMV пользователя на 30 дней

14 место из 316 · команда из 2

- 250 000 пользователей, 409 дней истории поиска и каталога. Постановка «пользователь и дата»: признаки строго до даты прогноза, схема обучения повторяет схему предсказания.
- Классификатор «обучение против теста» нашёл утечку даты якоря (AUC 1.0); после её удаления стало видно, что 93 % локального прироста были ложными.
- Обучение в шкале метрики (log1p), ансамбль GRU и градиентного бустинга. **RMSLE 1.6631** на приватной части.

OreScore - классификация сорта руды по микроскопии шлифов

Норникель AI Science Hack, финал

- Сегментация фаз U-Net на панорамах до 300 Мп; сорт руды выносится экспертным правилом по маске, на выходе карта уверенности и заключение.
- Доменный сдвиг между камерами: нормализация цвета подняла распознавание на новом домене с 5 до 14 проб из 20 без новой разметки.
- **macro-F1 0.91** по типу сростаний, **0.77 end-to-end**. Панорама за 124 с при нормативе 5 минут; FastAPI, Docker, 48 часов.

Stem Separator - разделение трека на 4 инструментальные дорожки

Demucs · FastAPI · Docker

- Разделение на вокал, ударные, бас и остальное на Demucs, замер через museval на MUSDB18-sample (5 треков): **SDR 9.34 dB** на вокале, **9.90 dB** на басе.
- Трёхминутный трек за 14 секунд. REST API, веб-интерфейс и CLI, автовыбор MPS/CUDA/CPU, 19 тестов, Docker.

НАУЧНАЯ РАБОТА

Сравнительная оценка генеративных моделей музыки через FAD

МГТУ, каф. ИУ5

- Разработал бенчмарк пяти open-source моделей генерации музыки по тексту: FAD, FAD-inf и CLAP Score, три эмбеддера, два референсных датасета.
- Показал, что рейтинг моделей зависит от выбора референса: **AudioLDM-M** на FMA-Pop, **MusicLDM** на MTG-Jamendo. FAD без указания референса несопоставим между работами.

ДОСТИЖЕНИЯ

- Yandex ML Challenge 2026 - **42 место из 100 финалистов**.
- ШАД Яндекса, интенсив «AI Agents Security Week». Классификатор запросов к LLM под политику Trust & Safety: 4 действия и 13 кодов причины, детерминированный TF-IDF-матчер. Улучшил стартовое решение с 61.54 до **99.81 из 100**. Red team на извлечение секрета из системного промпта - **71.43 из 100**.
- Хакатон DatsSol 2026 - **16 место из 166**.
- Норникель AI Science Hack 2026 - финалист.

ОБРАЗОВАНИЕ

МГТУ им. Н. Э. Баумана, факультет «Информатика и системы управления», кафедра ИУ5 - системы обработки информации и управления

бакалавриат, 4 курс, 2027

Профильные курсы: технологии машинного обучения, теория вероятностей и математическая статистика, базы данных, исследование операций.

НАВЫКИ

Основное: Python, pandas, polars, scikit-learn, CatBoost, LightGBM, PyTorch

Данные: SQL, PostgreSQL, оконные функции, dbt

Статистика: проверка гипотез, бутстрап, поправки на множественность, мощность и MDE, uplift-моделирование

ML и DL: табличные задачи и временные ряды, сегментация и детекция, аудио

Инженерия: Docker, FastAPI, pytest, Git, Linux

Языки: русский - родной; английский - B2, читаю техническую документацию и статьи